



## SCC5871 – Introdução ao Aprendizado de Máquina

---

### Aula 10 – Redes Neurais: Redes RBF e Regressão Não Linear

**Prof. Ricardo J. G. B. Campello**

PPG-CCMC / ICMC / USP



## Aula de Hoje

---

- Modelos RBF
- Estimação dos Pesos de Redes RBF
  - Mínimos Quadrados
  - Back-propagation
- Determinação das Funções Radiais
- Aplicações em Regressão Não Linear
  - Mapeamentos Estáticos, Séries Temporais e Sistemas Dinâmicos


## Redes RBF

- ◆ Redes RBF (*Radial Basis Functions*) são uma classe de redes com arquitetura *feedforward*
  - Assim como as MLPs, os valores das entradas se propagam na rede em um único sentido
- ◆ Essas redes diferem das MLPs especialmente no modelo de neurônio que utilizam
  - Neurônios com *resposta radial* a excitações
  - Modelam o conceito biológico de *campo receptivo*

3

## Redes RBF

- ◆ Resposta Radial Típica:



4

## Redes RBF

### ◆ Resposta Radial


- Presentes em alguns tipos de células nervosas:
  - Células auditivas: possuem maior sensibilidade a frequências *próximas* a um determinado tom
  - Células da retina: maior sensibilidade a excitações luminosas *próximas* ao centro do seu campo receptivo
- Modelo matemático:
  - **Função de Base Radial**

5

## Função de Base Radial

### ◆ Diferentes Modelos Matemáticos Possíveis

- Gaussiana: 
$$h(x) = \exp\left(-\frac{(x-c)^2}{\sigma^2}\right)$$




6

## Função de Base Radial

### ◆ Diferentes Modelos Matemáticos Possíveis

#### ■ Multi-Quadrática Inversa:

$$h(x) = \frac{1}{\sqrt{(x-c)^2 + \sigma^2}}$$




7

## Função de Base Radial

### ◆ Diferentes Modelos Matemáticos Possíveis

#### ■ Chapéu Mexicano:

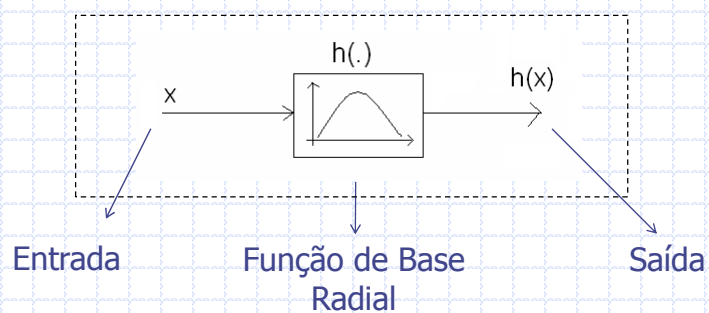
$$h(x) = \begin{cases} \frac{\sin((x-c)/\sigma)}{((x-c)/\sigma)} & \text{se } x \neq c \\ 1 & \text{caso contrário} \end{cases}$$



8


## Modelo do Neurônio RBF

### ◆ Modelo Básico do Neurônio:



9

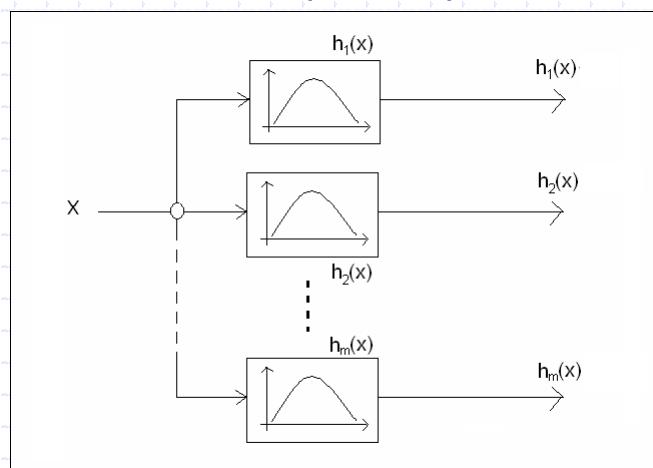
## Campos Receptivos Distintos



10

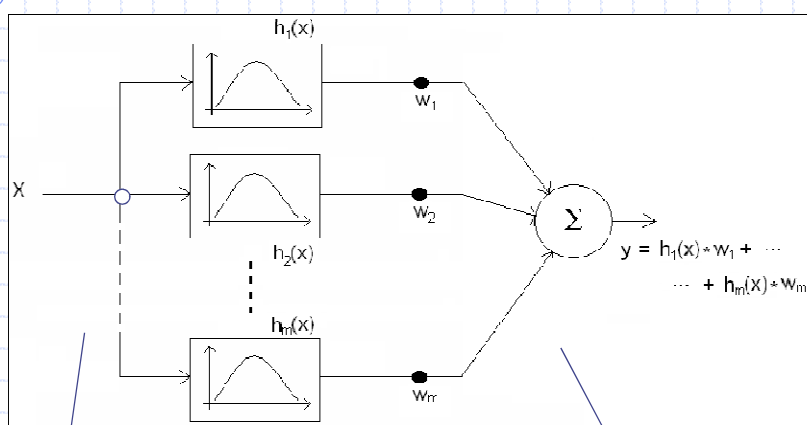
## Múltiplos Neurônios

- ◆ Neurônios com campos receptivos distintos:



11

## Modelo RBF (1 entrada)



"camada" entrada


camada intermediária

camada de saída  
(neurônio linear)

12

## Regressão Não Linear

◆ RBFs são **Aproximadores Universais** !




13

## Regressão Não Linear

◆ Tais como MLPs, RBFs são **Aproximadores Universais**:

- Basta aumentar o número de neurônios (funções de base radial) para obter a capacidade de aproximação desejada.
- Tomando cuidado com super-treinamento (*overfitting*) !



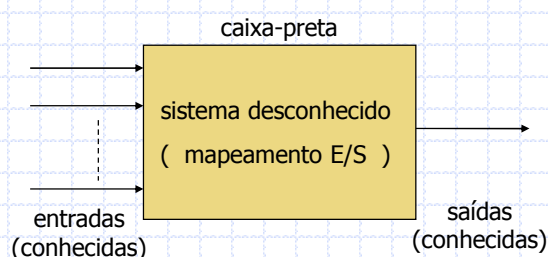
<http://people.sabanciuniv.edu/berrin/cs512/lectures/8-nn6-rbf.ppt> (09/2008)

14

## Regressão Não Linear

### ◆ RBFs são **Aproximadores Universais**:

- Diversos problemas podem ser representados como problemas de aproximação de funções
  - Previsão, Tomada de decisão, Classificação\*, etc
  - Por exemplo, operador humano de um processo complexo...




15

## Modelo RBF (2 entradas)

### ◆ Função Radial para 2 Entradas (Gaussiana):

$$h(x_1, x_2) = \exp\left(-\frac{(x_1 - c_1)^2}{\sigma_1^2}\right) \times \exp\left(-\frac{(x_2 - c_2)^2}{\sigma_2^2}\right)$$




16



## Modelo RBF (2 entradas)

◆ Função Radial para 2 Entradas (Gaussiana):


$$h(x_1, x_2) = \exp\left(-(\mathbf{x} - \mathbf{c})^T \cdot \begin{bmatrix} 1/\sigma_1^2 & 0 \\ 0 & 1/\sigma_2^2 \end{bmatrix} \cdot (\mathbf{x} - \mathbf{c})\right) \quad \begin{cases} \mathbf{x} = [x_1 & x_2]^T \\ \mathbf{c} = [c_1 & c_2]^T \end{cases}$$



17

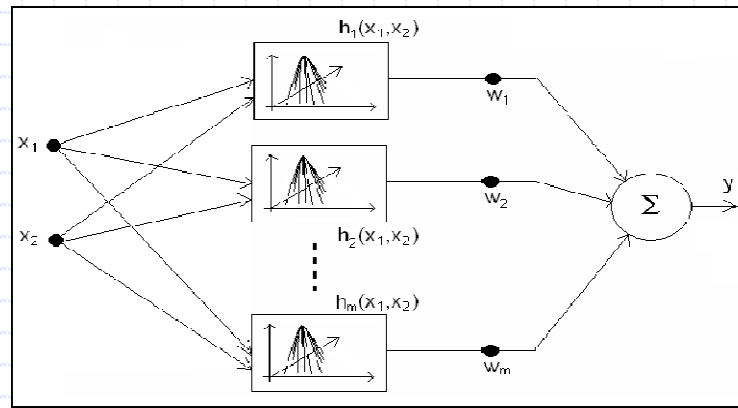
## Modelo RBF (2 entradas)

◆ Função Radial para 2 Entradas (Chapéu Mexicano):



18



## Modelo RBF (2 entradas)



$$y = \sum_{i=1}^m w_i \cdot h_i(x_1, x_2)$$

19

## Modelo RBF (2 entradas)



## Modelo RBF (n entradas)

- ◆ Função Radial para n Entradas (Gaussiana):

$$h(x_1, \dots, x_n) = \exp\left(-(\mathbf{x} - \mathbf{c})^T \cdot \Phi^{-1} \cdot (\mathbf{x} - \mathbf{c})\right)$$


$$\begin{cases} \mathbf{x} = [x_1 & \dots & x_n]^T \\ \mathbf{c} = [c_1 & \dots & c_n]^T \\ \Phi = \text{diag}(\sigma_1^2, \dots, \sigma_n^2) \end{cases}$$

- ◆ Nota: matriz  $\Phi$  não precisa ser diagonal

- flexibilidade x complexidade (no. de parâmetros)

21


## Modelo RBF (n entradas)



$$y = \sum_{i=1}^m w_i \cdot h_i(x_1, \dots, x_n) = \mathbf{w}^T \cdot \mathbf{h}$$

22

## Modelo RBF (n entradas / r saídas)



© Elena Marchiori

$$y_j = \sum_{i=1}^m w_{ji} \cdot h_i(x_1, \dots, x_n) \quad \text{ou} \quad \mathbf{y} = \mathbf{W} \cdot \mathbf{h}$$

23


## RBF vs. MLP

- Algumas diferenças e semelhanças entre RBFs e MLPs:

MLP	RBF
Aproximadores Universais	Aproximadores Universais
1 ou mais camadas intermediárias	Em geral 1 camada intermediária
Em geral demandam menos neurônios / parâmetros para uma mesma precisão	Em geral demandam mais neurônios / parâmetros para uma mesma precisão
Treinamento mais complexo	Treinamento mais simples
Difícil interpretação, senão impossível	Possível interpretação (se vista como sistema fuzzy)

24

## Nota (Adição de Termo Constante)




25

## Exercício (classificação)

- Sabemos que o problema XOR consiste em classificar 4 padrões (descritos por 2 variáveis) em 2 classes diferentes, ou seja:

$x_1$	$x_2$	Classe
0	0	1
0	1	2
1	0	2
1	1	1




Note que esse problema não é linearmente separável, ou seja, não existe uma função linear que separe as classes no espaço  $x_1 \times x_2$

26

## Exercício (cont.)


- No entanto, os padrões podem passar a ser linearmente separáveis após serem processados por funções de base radial, desde que essas sejam escolhidas de forma apropriada. P. ex., escolhendo 2 funções Gaussianas  $h_1$  e  $h_2$  com centros dados por  $[0,0]$  e  $[1,1]$ , respectivamente, e desvios padrão unitários para ambas, tem-se:

$x_1$	$x_2$	$h_1(x_1, x_2)$	$h_2(x_1, x_2)$
0	0	1	0,1353
0	1	0,3679	0,3679
1	0	0,3679	0,3679
1	1	0,1353	1



## Exercício (cont.)

- Considere então a rede RBF com essas funções de base radial e pesos  $w_1 = w_2 = -1$  e  $w_0 = 1$  (aditivo na saída):



- Escreva analiticamente a expressão da saída da rede em função das entradas  $x_1$  e  $x_2$  e mostre que essa rede é capaz de classificar corretamente os padrões XOR assumindo que esses padrões pertencem à classe 1 se  $y < 0$  e à classe 2 se  $y > 0$

## Treinamento de Redes RBF

### ◆ Problemas:

- Dadas as funções de base radial, como determinar o melhor vetor de pesos  $\mathbf{w}$  ?
- Como determinar bons parâmetros para as funções de base radial (centros e aberturas) ?
  - reduzir no. de funções para dada precisão, ou
  - aumentar precisão para dado no. de funções

29

## Treinamento de Redes RBF

### ◆ Problemas:

- **Dadas as funções de base radial, como determinar o melhor vetor de pesos  $\mathbf{w}$  ?**
- Como determinar bons parâmetros para as funções de base radial (centros e aberturas) ?
  - reduzir no. de funções para dada precisão, ou
  - aumentar precisão para dado no. de funções

30

## Determinação dos Pesos

- ◆ Queremos determinar os pesos de uma rede RBF com funções radiais conhecidas para aproximar a função (mapeamento) entre um conjunto de  $N$  padrões de entrada  $\mathbf{x}_k = [x_{1k} \dots x_{nk}]^T$  e saída  $y(\mathbf{x}_k)$  para  $k=1, \dots, N$ 
  - Por simplicidade, assume-se aqui que a saída é única
- ◆ Exemplo:
  - ◆ para  $N = 100$  clientes de um banco, descritos por  $n = 5$  variáveis (salário, idade, tempo de relacionamento com o banco, sexo, estado civil), queremos obter uma rede que, dado um cliente  $\mathbf{x}_k$ , responda se este cliente possui maior risco de ser caloteiro ( $y(\mathbf{x}_k) = 1$ ) ou não ( $y(\mathbf{x}_k) = 0$ )

31

## Determinação dos Pesos

- ◆ Como as  $m$  funções radiais são conhecidas, podemos calcular o valor dessas funções para cada padrão  $\mathbf{x}_k$
- ◆ Representando esses valores em uma matriz tem-se:
 
$$\mathbf{H} = \begin{bmatrix} h_1(\mathbf{x}_1) & \dots & h_m(\mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ h_1(\mathbf{x}_N) & \dots & h_m(\mathbf{x}_N) \end{bmatrix}$$
- ◆ As saídas desejadas (conhecidas) também podem ser representadas em um vetor:

$$\mathbf{y} = [y(\mathbf{x}_1) \quad \dots \quad y(\mathbf{x}_N)]^T$$

32



## Determinação dos Pesos

- ◆ Para uma representação ideal da saída, deseja-se que a rede RBF possua pesos  $\mathbf{w}$  tais que:

$$\begin{bmatrix} h_1(\mathbf{x}_1) & \cdots & h_m(\mathbf{x}_1) \\ \vdots & \ddots & \vdots \\ h_1(\mathbf{x}_N) & \cdots & h_m(\mathbf{x}_N) \end{bmatrix} \cdot \begin{bmatrix} w_1 \\ \vdots \\ w_m \end{bmatrix} = \begin{bmatrix} y(\mathbf{x}_1) \\ \vdots \\ y(\mathbf{x}_N) \end{bmatrix}$$

ou seja:  $\mathbf{H} \cdot \mathbf{w} = \mathbf{y}$

- ◆ Se  $\mathbf{H}$  fosse quadrada, poderíamos multiplicar por  $\mathbf{H}^{-1}$  em ambos os lados e resolver o problema como:

$$\mathbf{w} = \mathbf{H}^{-1} \cdot \mathbf{y}$$

33

## Determinação dos Pesos

- ◆ Podemos obter uma matriz quadrada multiplicando ambos os lados da equação por  $\mathbf{H}^T$ :

$$\mathbf{H}^T \cdot \mathbf{H} \cdot \mathbf{w} = \mathbf{H}^T \cdot \mathbf{y}$$

- ◆ Agora sim podemos multiplicar ambos os lados da equação pela inversa  $(\mathbf{H}^T \mathbf{H})^{-1}$  e obter a solução como:

$$\mathbf{w} = (\mathbf{H}^T \cdot \mathbf{H})^{-1} \cdot \mathbf{H}^T \cdot \mathbf{y}$$

34

## Determinação dos Pesos

- ◆ Se houver o termo aditivo  $w_0$  na saída, é preciso somente redefinir  $\mathbf{H}$  e  $\mathbf{w}$  de tal forma que:

$$\underbrace{\begin{bmatrix} 1 & h_1(\mathbf{x}_1) & \cdots & h_m(\mathbf{x}_1) \\ \vdots & \vdots & \ddots & \vdots \\ 1 & h_1(\mathbf{x}_N) & \cdots & h_m(\mathbf{x}_N) \end{bmatrix}}_{\mathbf{H}} \cdot \underbrace{\begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_m \end{bmatrix}}_{\mathbf{w}} = \underbrace{\begin{bmatrix} y(\mathbf{x}_1) \\ \vdots \\ y(\mathbf{x}_N) \end{bmatrix}}_{\mathbf{y}}$$

o que não afeta a solução:

$$\mathbf{w} = (\mathbf{H}^T \cdot \mathbf{H})^{-1} \cdot \mathbf{H}^T \cdot \mathbf{y}$$

35

## Determinação dos Pesos

- ◆ Algoritmo:

- ◆ Para um conjunto de  $k = 1, \dots, N$  padrões de entrada e saída,  $\{\mathbf{x}_k, y(\mathbf{x}_k)\}$ , calcule a matriz  $\mathbf{H}$ , construa o vetor  $\mathbf{y}$  e calcule os pesos da rede segundo a equação:

$$\mathbf{w} = (\mathbf{H}^T \cdot \mathbf{H})^{-1} \cdot \mathbf{H}^T \cdot \mathbf{y}$$


- ◆ Nota: É possível demonstrar que, se a representação não for exata, a solução acima é aquela que minimiza o erro quadrático entre a saída da rede e a saída desejada (**Mínimos Quadrados**) !

36

## Exercício (classificação)

- ◆ Sabemos que o problema XOR consiste em classificar  $N = 4$  padrões (descritos por  $n = 2$  variáveis) em 2 classes diferentes:

k	$x_1$	$x_2$	y (classe)
1	0	0	0
2	0	1	1
3	1	0	1
4	1	1	0




Note que esse problema não é linearmente separável, ou seja, não existe uma função linear que separe as classes no espaço  $x_1 \times x_2$

37

## Exercício (cont.)


- ◆ No entanto, os padrões podem passar a ser linearmente separáveis após serem processados por funções de base radial, desde que essas sejam escolhidas de forma apropriada. P. ex., escolhendo 2 funções Gaussianas  $h_1$  e  $h_2$  com centros dados por  $[0,0]$  e  $[1,1]$ , respectivamente, e desvios padrão unitários para ambas, tem-se:

$x_1$	$x_2$	$h_1(x_1, x_2)$	$h_2(x_1, x_2)$
0	0	1	0,1353
0	1	0,3679	0,3679
1	0	0,3679	0,3679
1	1	0,1353	1



## Exercício (cont.)

- ◆ Considere então a rede RBF com essas funções de base radial e pesos  $w_1$  e  $w_2$ , além do peso adicional  $w_0$  (aditivo na saída), conforme abaixo:



- ◆ Obtenha os valores dos pesos  $w_0$ ,  $w_1$  e  $w_2$  para que a rede consiga indicar precisamente em sua saída a classe correta (0 ou 1) de cada um dos 4 padrões de entrada do problema XOR.
- Apresente a solução passo a passo, em detalhes e de forma justificada !

39

## Determinação das Funções Radiais

### ◆ Método 1 (Heurística Simples):

- Distribuir as funções de maneira homogênea sobre o domínio das variáveis de entrada
- Por exemplo, se a rede possui duas entradas,  $x_1$  e  $x_2$ , que assumem valores no intervalo  $[-10, +10]$ , então o domínio das funções são todos os pontos  $(x_1, x_2)$  tais que  $x_1 \in [-10, +10]$  e  $x_2 \in [-10, +10]$

40

## Determinação das Funções Radiais


### ◆ Método 1 (cont.):

- Os centros das funções com relação a cada variável (dimensão) podem ser distribuídos uniformemente (eqüidistantes) ao longo do domínio daquela var.
- As aberturas das funções (desvios padrão) com relação a cada variável podem ser feitas iguais à distância entre dois centros consecutivos.

41

## Determinação das Funções Radiais

### ◆ Método 1 (exemplo):



42

## Determinação das Funções Radiais

### ◆ Método 2 (back-propagation):

- Análogo ao treinamento de MLPs
- A cada iteração ajusta-se o conjunto de parâmetros (centros e aberturas das funções) no sentido de minimizar o erro entre a saída da rede e a saída desejada para um conjunto de padrões
- Usualmente tenta-se minimizar:  $J = \frac{1}{N} \sum_{k=1}^N (y(\mathbf{x}_k) - y_{\text{RBF}}(\mathbf{x}_k))^2$
- Demanda o cálculo do gradiente (derivadas) de J com relação aos parâmetros...
- **Usualmente aplica-se para refinar o resultado inicial obtido com o método 1 ou método 3 (visto depois)**

43

## Exemplo (regressão)

### ◆ Problema:

- Aproximar a função  $f(x) = \sin(2x) / \exp(x/5)$
- ◆ N = 21 padrões de entrada e saída (k = 1, ..., 21):


Padrão E/S	x	f(x)
1	0	0
2	0.5	0.7614
3	1.0	0.7445
4	1.5	0.1045
5	2.0	-0.5073
6	2.5	-0.5816
7	3.0	-0.1533
8	3.5	0.3262
9	4.0	0.4445
10	4.5	0.1676

11	5.0	-0.2001
12	5.5	-0.3329
13	6.0	-0.1616
14	6.5	0.1145
15	7.0	0.2443
16	7.5	0.1451
17	8.0	-0.0581
18	8.5	-0.1756
19	9.0	-0.1241
20	9.5	0.0224
21	10.0	0.1236

44

## Exemplo (cont.)

◆ **Problema:** Aproximar a função  $f(x) = \sin(2x) / \exp(x/5)$



45

## Exemplo (cont.)


◆ **Solução 1 (Método 1):**

- Rede RBF com 6 neurônios (funções Gaussianas)
- Centros distribuídos de maneira uniforme
  - $c_1 = 0, c_2 = 2, c_3 = 4, c_4 = 6, c_5 = 8, c_6 = 10$
- Desvios padrão iguais à distância entre dois centros consecutivos
  - $\sigma_1 = \sigma_2 = \sigma_3 = \sigma_4 = \sigma_5 = \sigma_6 = 2$
- Apenas os pesos otimizados via Mínimos Quadrados (MQ):
  - 7 pesos ( $w_0 \dots w_6$ ) obtidos via MQ:  $\mathbf{w} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

46

## Exemplo (cont.)

### ◆ Resultado Solução 1:



47

## Exemplo (cont.)

### ◆ Solução 2 (Método 1):


- Rede RBF com 11 neurônios
- Centros distribuídos de maneira uniforme
  - $c_1 = 0, c_2 = 1, c_3 = 2, \dots, c_{11} = 10$
- Desvios padrão iguais à distância entre dois centros consecutivos
  - $\sigma_1 = \sigma_2 = \dots = \sigma_{11} = 1$
- Apenas os pesos otimizados via Mínimos Quadrados (MQ):
  - 12 pesos ( $w_0 \dots w_{11}$ ) obtidos via MQ:  $\mathbf{w} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{y}$

48



## Exemplo (cont.)

### ◆ Resultado Solução 2:



49

## Exemplo (cont.)


### ◆ Solução 3 (Método 1 + 2):

- Rede RBF com 6 neurônios
- Rede inicialmente configurada conforme Solução 1
- Sintonia fina realizada com **back-propagation**

50

## Exemplo (cont.)

### ◆ Resultado Solução 3:



51

## Exemplo (cont.)


### ◆ Solução 4 (Método 1 + 2):

- Rede RBF com 8 neurônios
- Rede inicialmente configurada de forma análoga à Solução 1
  - Porém com 8 neurônios (Gaussianas)
- Sintonia fina realizada com **back-propagation**

52


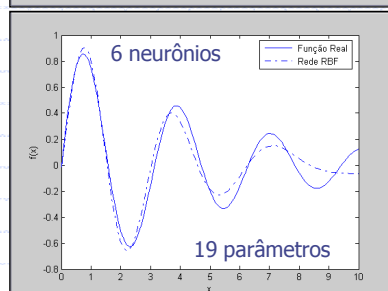


## Exemplo (cont.)

### Resultado Solução 4:



53

## Exemplo (cont.)



4

## Exemplo (cont.)


### ◆ Comparação:

- A heurística de distribuição homogênea das funções radiais (método 1) foi muito eficaz nesse exemplo agindo sozinha, mas não necessariamente é sempre assim
- Embora a rede com 8 neurônios refinados com back-propagation tenha uma quantidade de parâmetros maior durante a fase de **treinamento**, é um modelo mais simples e compacto do que aquele com 11 neurônios (para **utilização**).
- A rede com 11 neurônios poderia ficar ainda mais precisa se seus parâmetros também fossem refinados com back-propagation

55

## Dicas Básicas

- ◆ Usualmente utiliza-se apenas uma parcela dos padrões disponíveis para treinar a rede e reserva-se uma outra parcela para teste ou **validação**
- ◆ Uma boa heurística para saber quando interromper o treinamento (sintonia fina) dos parâmetros via back-propagation é observar os erros de ambas as parcelas:




➡ **Early Stop**

56

## Dicas Básicas

- ◆ A mesma idéia pode ser usada para determinar quando parar de acrescentar neurônios à rede...



- ◆ Uma outra boa dica é normalizar os padrões de E/S de forma que cada variável tenha valores entre  $-1$  e  $+1$ 
  - Isso minimiza problemas numéricos durante o treinamento

57

## Determinação das Funções Radiais

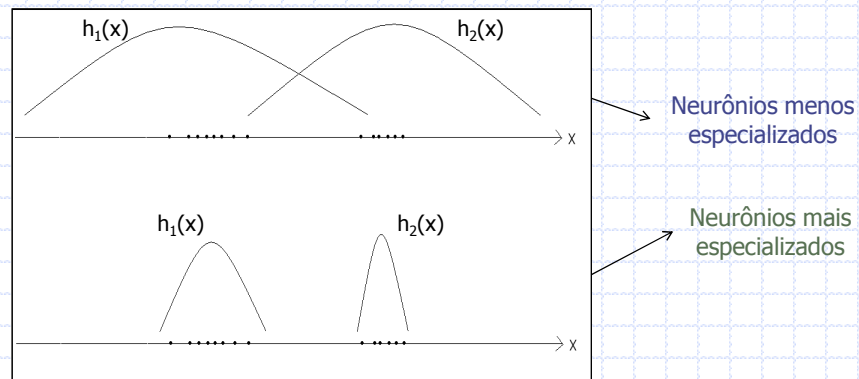
- ◆ **Método 3** (Clustering – Vide Próxima Aula):
  - Agrupar os padrões em grupos (clusters) de padrões mais similares entre si do que aos demais padrões.
  - Associar um neurônio (função radial) para cada grupo de padrões, otimizando a representatividade de cada neurônio / função.
  - Idéia é que cada neurônio responda de forma apropriada e similar a um determinado conjunto de padrões similares
    - Tipicamente (sub)classes em **problemas de classificação**

58

## Determinação das Funções Radiais

### ◆ Método 3 (cont.):

- Idéia intuitiva (1 var. de entrada):




59

## Determinação das Funções Radiais

### ◆ Método 3 (cont.):

- Idéia intuitiva (2 vars. de entrada):



60

## Determinação das Funções Radiais

### ◆ Método 3 (cont.):

- Um dos algoritmos de agrupamento mais populares é o **K-means**, que agrupa N padrões em K grupos
  - fornece K protótipos (centróides) dos grupos
- K-means agrupa os N padrões em K grupos com o objetivo de minimizar as distâncias entre os padrões pertencentes a um mesmo grupo e seu protótipo
  - veremos na próxima aula...
- Mas como aplicar K-means para determinação das funções radiais...?

61

## Determinação das Funções Radiais


### ◆ Método 3 (cont.):

- Executa-se K-means com **K** igual ao número **m** de neurônios (funções radiais) desejado na rede RBF
- Toma-se o protótipo (centróide) de cada grupo resultante como centro de uma função radial
  - cada componente do centróide é o centro da função radial correspondente na respectiva variável
- Toma-se os desvios padrão de cada grupo, em cada variável, como o desvio padrão da função radial correspondente na respectiva variável
  - forma simplificada...

62

## Método 3 (Exemplo)

padrão (entrada)	$x_1$	$x_2$
1	1	2
2	2	1
3	1	1
4	2	2
5	8	9
6	9	8
7	9	9
8	8	8
9	1	15
10	2	15
11	1	14
12	2	14



Slide cedido pelo Prof. Eduardo Raul Hruschka

## Método 3 (Exemplo)

- ◆ K-means com  $K = 3$  produziria tipicamente os protótipos  $(1.5, 1.5)$ ,  $(8.5, 8.5)$ ,  $(1.5, 14.5)$
- ◆ O terceiro grupo, por exemplo, possui desvios padrão em  $x_1$  e em  $x_2$  respectivamente iguais a:

$$\sigma_1 = \sqrt{\frac{(1-1.5)^2 + (2-1.5)^2 + (1-1.5)^2 + (2-1.5)^2}{4}} = 0.5$$

$$\sigma_2 = \sqrt{\frac{(15-14.5)^2 + (15-1.5)^2 + (14-14.5)^2 + (14-14.5)^2}{4}} = 0.5$$

- ◆ Logo, a função radial (Gaussiana) correspondente pode ser definida como:

$$h_3(x_1, x_2) = \exp\left(-\frac{(x_1 - 1.5)^2}{0.5^2}\right) \times \exp\left(-\frac{(x_2 - 14.5)^2}{0.5^2}\right)$$



## RBFs em Problemas de Regressão

- ◆ Em problemas de **regressão não linear**, a mesma arquitetura RBF é usada para modelar uma função  $F$ :
  - Na aproximação de **mapeamentos estáticos**
    - ◆  $y = F(x_1, x_2, \dots, x_n)$
    - ◆ Exemplo:  $y = (1 / x_1) + (x_2)^{1/2}$
  - Em previsão de **séries temporais**
    - ◆  $y_t = F(y_{t-i}, y_{t-j}, \dots, y_{t-k})$
    - ◆ Exemplo:  $y_t = 10y_{t-3} - (y_{t-5})^3 + \exp(-y_{t-8})$
  - Na modelagem de **sistemas dinâmicos**
    - ◆  $y_t = F(u_{t-1}, u_{t-2}, \dots, u_{t-p}, y_{t-1}, y_{t-2}, \dots, y_{t-q})$
    - ◆ Exemplo:  $y_t = 3y_{t-1} + (u_{t-1})^{-1/2}$



## Leitura e Exercícios

- Seção 9.1 de (Braga et al., 2007)
- ou
- Capítulo 5 de (Haykin, 1999)



## Referências

---

- Haykin, S., *Neural Networks: A Comprehensive Foundation*, Prentice Hall, 2nd Edition, 1999
- Braga, A. P., Carvalho, A. C. P. L. F., Ludemir, T. B., *Redes Neurais Artificiais: Teoria e Aplicações*, LTC, 2ª Edição, 2007
- Kovács, *Redes Neurais Artificiais: Fundamentos e Aplicações*, Collegium Cognitio, 2ª Edição, 1996